



**TECNOLÓGICO  
NACIONAL DE MÉXICO**



**Tecnológico Nacional de México – Campus  
Culiacán**

**Tópicos de IA**

**Alumnos:**

**Sarabia Guzmán Jesús Aldhair  
Zamudio Lizárraga Bryan Martín**

**Proyecto de Investigación: Inteligencia Artificial e  
Impacto Ambiental**

**Sistema Predictivo Basado en Random Forest para  
la Detección de Fugas en Redes de Agua**

**17 de septiembre de 2026**

**Repositorio: <https://github.com/bryan-zamudio/Topicos-IA/tree/main>**

## Contenido

|                                                                |           |
|----------------------------------------------------------------|-----------|
| <b>Introducción.....</b>                                       | <b>3</b>  |
| <b>Objetivo General .....</b>                                  | <b>4</b>  |
| <b>Objetivos Específicos.....</b>                              | <b>4</b>  |
| <b>Justificación.....</b>                                      | <b>5</b>  |
| <b>Alcance .....</b>                                           | <b>6</b>  |
| <b>Desarrollo.....</b>                                         | <b>7</b>  |
| <b>1. Desafíos Detectados en el Monitoreo Hidráulico .....</b> | <b>7</b>  |
| <b>2. Evaluación del Estado del Arte en IA.....</b>            | <b>7</b>  |
| <b>3. Propuesta Técnica y Flujo de Trabajo .....</b>           | <b>8</b>  |
| <b>Agenda .....</b>                                            | <b>10</b> |
| <b>Conclusiones .....</b>                                      | <b>11</b> |
| <b>Referencias .....</b>                                       | <b>12</b> |

## Introducción


La pérdida masiva de agua potable en redes de distribución subterráneas representa una de las mayores problemáticas ecológicas actuales. En las redes urbanas de distribución, una porción grande del agua tratada e inyectada al sistema nunca llega al consumidor final, clasificándose como agua no contabilizada. En países en desarrollo y particularmente en México, se desperdicia entre el 40% y el 50% del agua potable a través de fracturas y rupturas no detectadas a tiempo.

Este desperdicio crónico desencadena graves consecuencias ecológicas. Provoca la sobreexplotación continua de los mantos, demanda un gasto energético continuo innecesario en los sistemas de bombeo municipal e incrementa el riesgo de daños físicos al subsuelo mediante socavamiento y contaminación. Dado que la mayoría de las tuberías están enterradas en el entorno urbano, la inspección visual es inviable salvo en fallas masivas evidentes. A la vez, los métodos tradicionales basados en hardware (inspección acústica, gas trazador o georradar) resultan costosos, lentos y difíciles de mantener para una cobertura continua en toda la ciudad.

El aprendizaje automático (*Machine Learning*) ofrece una alternativa viable para procesar variables hidráulicas operativas (presión y caudal) y transformarlas en alertas oportunas. Mediante el entrenamiento de clasificadores supervisados combinados con simuladores hidráulicos estándar como EPANET, es posible diagnosticar fallas y ver la ubicación de rupturas sin exigir un supercómputo ni una cantidad demasiado densa de sensores en la red.

## Objetivo General

Diseñar un sistema de monitoreo y detección temprana de fugas de agua basado en el algoritmo de aprendizaje automático Random Forest y modelos de simulación hidráulica en EPANET, con el fin de optimizar la localización de anomalías en redes urbanas y mitigar el desperdicio del recurso hídrico.



*Ilustración 1 EPANET, software que permite simular redes hidráulicas*

## Objetivos Específicos

1. **Analizar los desafíos y soluciones del estado del arte** en detección de fugas mediante el contraste de técnicas tradicionales frente a modelos de aprendizaje automático supervisado.
2. **Generar escenarios de calibración y falla hidráulica en EPANET** para simular caídas de presión y variaciones de flujo bajo condiciones normales y de ruptura sin alterar la red física.
3. **Entrenar y validar un modelo clasificador Random Forest** en lenguaje Python para distinguir eventos normales de fugas y clasificar el cuadrante o zona afectada a partir de lecturas nodales de presión.

4. **Diseñar una propuesta de interfaz visual amigable** que permita a los operadores de agua monitorear el estado de la red e interpretar alertas tempranas de manera directa.

**Justificación**


La magnitud del desperdicio de agua potable a nivel global evidencia la necesidad de herramientas predictivas. Como se aprecia en los datos comparativos de Liemberger y Wyatt (*Burciaga et al., 2026*), el volumen perdido en redes urbanas alcanza dimensiones críticas:

Tabla 1. Cifras estimadas de agua desperdiciada por país

| <i><b>País</b></i>                          | <i><b>Agua desperdiciada<br/>(m3/día)</b></i> | <i><b>Porcentaje de agua<br/>desperdiciada</b></i> |
|---------------------------------------------|-----------------------------------------------|----------------------------------------------------|
| <i><b>Alemania</b></i>                      | 2,030,621                                     | 15%                                                |
| <i><b>Brasil</b></i>                        | 18,872,182                                    | 39%                                                |
| <i><b>China</b></i>                         | 44,688,202                                    | 21%                                                |
| <i><b>Dinamarca</b></i>                     | 69,888                                        | 7%                                                 |
| <i><b>Estados Unidos de<br/>América</b></i> | 39,068,076                                    | 20%                                                |
| <i><b>Nigeria</b></i>                       | 738,259                                       | 39%                                                |
| <i><b>México</b></i>                        | 12,425,811                                    | 40%                                                |
| <i><b>Países Bajos</b></i>                  | 146,196                                       | 5%                                                 |

En México se pierden más de 12.4 millones de m<sup>3</sup> diarios (el 40% del agua distribuida), y en regiones críticas del norte del país como Chihuahua, la eficiencia física cae al 52%, perdiéndose el 48% del suministro inyectado.

Frente a este escenario, las empresas de agua operan sistemas que almacenan datos en bruto pero carecen de módulos automáticos para discernir si una caída de presión responde a la demanda cotidiana en horas pico o a una fractura real. La IA soluciona esta brecha aprendiendo del comportamiento histórico para delimitar el área de búsqueda de kilómetros de tubería a sectores específicos. Su aplicación reduce los tiempos de detección de semanas a horas y aprovecha la infraestructura de medición existente sin exigir presupuestos inaccesibles.



*Ilustración 2 Representación simplificada de un sistema moderno de distribución de agua*

## Alcance

- **Datos y simulación:** Construcción de un modelo hidráulico de referencia mediante el software libre EPANET para obtener series temporales de flujo y presión ante diversos escenarios de operación normal y roturas simuladas.
- **Tratamiento algorítmico:** Entrenamiento del algoritmo Random Forest implementado con librerías estándar (scikit-learn, pandas) para realizar una clasificación binaria (*Fuga / Sin fuga*) y una zonificación orientada a delimitar el sector afectado.
- **Entorno computacional:** Configuración de una herramienta ligera ejecutable en computadoras convencionales de oficina (hardware estándar con CPU multinúcleo y 8 GB de RAM) monitorizada mediante una interfaz web básica de visualización.
- **Límites:** El proyecto no contempla la excavación física de terrenos, la reparación mecánica de tuberías ni la fabricación de nuevo instrumental electrónico.

## Desarrollo

### 1. Desafíos Detectados en el Monitoreo Hidráulico

- **Infraestructura no visible:** El enterramiento de las redes impide la inspección visual oportuna.
- **Limitación de sensores nodales:** Las redes reales poseen una cantidad de sensores muy inferior a la cantidad total de nodos e intersecciones. Colocar sensores en cada cruce es inviable por costos de instalación y mantenimiento.
- **Confusión por dinámicas de consumo:** La apertura de múltiples grifos en horas pico genera caídas de presión similares a las producidas por pequeñas fisuras, provocando falsas alarmas si se emplean umbrales fijos.
- **Ruido e interacción entre sectores:** Las vibraciones ambientales contaminan las lecturas y la interconexión hidráulica hace que la presión de una zona vecina se altere por una rotura lejana.

### 2. Evaluación del Estado del Arte en IA

Los estudios demuestran que los métodos de aprendizaje supervisado presentan un desempeño sobresaliente en la clasificación hidráulica:

- **Modelos supervisados:** Random Forest, Árboles de Decisión y Redes Neuronales Artificiales (ANN) alcanzan precisiones entre 95% y 100% bajo condiciones limpias y controladas. (*Adraoui et al., 2024*)
- **Fallas del aprendizaje no supervisado:** Algoritmos como K-Means o agrupamiento jerárquico no logran separar los datos correctamente debido a que las zonas de presión se solapan en el espacio dimensional.
- **Sensibilidad al ruido:** La presencia de ruido operacional reduce la exactitud de modelos lineales convencionales como la Regresión Logística a un 80.25%. No obstante, los modelos de ensamble basados en árboles (Random Forest) ofrecen alta resistencia al sobreajuste y estabilidad general (*Mashadi et al., 2021*):

Podemos observar esta tabla para comparar entre el antes y el después de usar los modelos de IA en este ámbito:

Tabla 2. Desempeño comparativo de modelos de IA con y sin acondicionamiento de datos (Shin et al., 2024)


| Algoritmo              | Accuracy<br>(Sin IA) | Accuracy<br>(Con IA) | F1-Score<br>(Sin IA) | F1-Score<br>(Con IA) |
|------------------------|----------------------|----------------------|----------------------|----------------------|
| XGBoost (XGB)          | 0.9570               | <b>0.9827</b>        | 0.9699               | <b>0.9849</b>        |
| Decision Tree          | 0.9434               | <b>0.9827</b>        | 0.9604               | <b>0.9849</b>        |
| Random Forest          | 0.9558               | <b>0.9814</b>        | 0.9690               | <b>0.9838</b>        |
| Extra Trees            | 0.9530               | <b>0.9820</b>        | 0.9672               | <b>0.9844</b>        |
| CatBoost               | 0.9542               | <b>0.9820</b>        | 0.9680               | <b>0.9844</b>        |
| K-Neighbors            | 0.9558               | <b>0.9807</b>        | 0.9689               | <b>0.9833</b>        |
| Logistic<br>Regression | 0.8025               | <b>0.9801</b>        | 0.8780               | <b>0.9827</b>        |

### 3. Propuesta Técnica y Flujo de Trabajo

Para entender de forma directa la propuesta, esta se resume en crear un gemelo digital de una red de agua (usando **EPANET**) para enseñarle a un algoritmo de IA (Random Forest) cómo se comporta el agua cuando todo está normal frente a cuando ocurre una ruptura subterránea. Decidimos usar Random Forest ya que es un modelo que lidia bastante bien con el ruido, algo que es muy común al usar los sensores.

De esta forma, cuando los sensores de la ciudad registren una caída de presión, la IA puede saber en minutos si se trata de una fuga o de un simple consumo alto y en qué sector específico está ocurriendo.

El sistema propuesto opera mediante una integración estructurada en tres etapas:



1. **Generación de datos sintéticos con EPANET:** Debido al riesgo y costo de inducir fugas reales en tuberías operativas, se configura una réplica digital de la red en EPANET. Se simulan consumos regulares y variaciones de presión inducidas por fugas en diferentes nodos.
2. **Entrenamiento con Random Forest:** El modelo combina múltiples árboles de decisión sobre los registros de presión y flujo. Esto previene el sobreajuste y permite reconocer caídas sutiles de presión para identificar la presencia de una fuga y localizar el cuadrante que es responsable.
3. **Plataforma web de alerta:** Las salidas del modelo se muestran en un tablero gráfico donde los técnicos visualizan el estado de la red sin requerir conocimientos avanzados de programación.

### ¿En qué consiste exactamente nuestra propuesta?

1. **Simulación Inteligente (Gemelo Digital):** Como no podemos ir rompiendo tuberías reales en la ciudad para capturar datos, se recrea la red de distribución en un software libre llamado **EPANET**. Ahí se simulan años de operación, cambios de demanda a distintas horas y rupturas de varios tamaños en diferentes puntos de la ciudad.

2. **Entrenamiento del Algoritmo (Random Forest):** Se toma toda esa información de presiones y caudales y se le entrega al modelo de Machine Learning. El algoritmo aprende a identificar "firmas hidráulicas", o sea, patrones sutiles de caída de presión que diferencian el uso cotidiano del agua de una fuga activa.
3. **Zonificación y Alertas:** En lugar de decirle al operario *"hay una fuga en alguna parte de los 50 km de red"*, el sistema clasifica la falla por sectores o cuadrantes pequeños y emite una alerta gráfica en una pantalla web, indicando exactamente qué zona enviar a revisar.

## Agenda

El proyecto se organiza en 6 fases a desarrollarse a lo largo de un período estimado de 24 semanas:

**Tabla 3. Agenda general de trabajo**

| <b>Fase</b> | <b>Actividades Principales</b>                                                                | <b>Semanas</b> |
|-------------|-----------------------------------------------------------------------------------------------|----------------|
| <b>1</b>    | Investigación documental, y análisis de antecedentes                                          | 1 - 4          |
| <b>2</b>    | Construcción del modelo digital de la red y simulación de escenarios de fuga en EPANET.       | 5 - 8          |
| <b>3</b>    | Preprocesamiento y estructuración del conjunto de datos en Python.                            | 9 - 12         |
| <b>4</b>    | Entrenamiento, ajuste de parámetros y validación del modelo Random Forest.                    | 13 - 17        |
| <b>5</b>    | Desarrollo e integración de la interfaz web básica para monitoreo visual de alertas.          | 18 - 21        |
| <b>6</b>    | Pruebas integrales de desempeño, redacción del documento final y preparación de diapositivas. | 22 - 24        |

## **Conclusiones**

La pérdida de agua potable en redes de transporte subterráneas representa una problemática ecológica crítica que no puede resolverse con métodos visuales o medios tradicionales. La integración de herramientas de simulación hidráulica abierta como EPANET junto a modelos clásicos de aprendizaje automático supervisado constituye una alternativa accesible y fundamentada.

El uso de Random Forest demuestra ser una elección robusta para este propósito. Su capacidad para manejar el ruido que representan los sensores en las tuberías de las redes de agua resulta bastante útil.

Al estructurarse sobre librerías estándar en Python y computación convencional, la propuesta es técnica y económicamente factible para organismos operadores locales. Esto facilita acortar los tiempos de respuesta ante fallas ocultas, reducir el consumo eléctrico asociado y preservar las reservas subterráneas de agua.

## Referencias

- Burciaga, A. H. N., Santillán, J. R. L., & Gurrola, L. C. G. (2026). Del dato a la gota: uso de Inteligencia Artificial para la detección de fugas de agua en Chihuahua. *Ciencia Vital*, 4(2), 1-8.  
<https://doi.org/10.20983/cienciavital.2026.02.apl.02>
- Adraoui, M., Azmi, R., Chenal, J., Diop, E. B., Abdem, S. A. E., Serbouti, I., Hlal, M., & Bounabi, M. (2024). A two-phase approach for leak detection and localization in water distribution systems using wavelet decomposition and machine learning. *Computers & Industrial Engineering*, 197, 110534.  
<https://doi.org/10.1016/j.cie.2024.110534>
- Mashhadi, N., Shahrou, I., Attoue, N., Khattabi, J. E., & Aljer, A. (2021). Use of Machine Learning for Leak Detection and Localization in Water Distribution Systems. *Smart Cities*, 4(4), 1293-1315.  
<https://doi.org/10.3390/smartcities4040069>
- Shin, Y., Na, K. Y., Kim, S. E., Kyung, E. J., Choi, H. G., & Jeong, J. (2024). LSTM-Autoencoder Based Detection of Time-Series Noise Signals for Water Supply and Sewer Pipe Leakages. *Water*, 16(18), 2631.  
<https://doi.org/10.3390/w16182631>